

MEMO PHƯƠNG PHÁP LÀM SẠCH DỮ LIỆU

Quy trình bảo đảm độ tin cậy, phản biện kỹ thuật và truy vết sai lệch dữ liệu trước phân tích

Tài liệu	Memo Phương pháp Làm sạch Dữ liệu (Data Cleaning Methodology Memo)
Phạm vi	06 nhóm nhân sự – tổng 20.099 phản hồi thô (raw)
Mục đích	Giải trình quy trình và căn cứ kỹ thuật để Ban Giám đốc tin cậy số liệu nền trước khi phân tích
Người lập	Bộ phận Phân tích Dữ liệu (People Analytics) – Ban Dự án EES 2026

1. Tóm tắt cho Ban Lãnh đạo

Triết lý làm sạch áp dụng cho EES 2026 là **giảm trọng số thay vì xóa bỏ**. Thay vì dùng một ngưỡng cứng để loại bản ghi (cách truyền thống vừa bắt nhầm người trả lời thật, vừa bỏ sót người trả lời loạn), mỗi phản hồi được gán một **trọng số tin cậy liên tục từ 0,1 đến 1,0**. Bản ghi đáng ngờ bị hạ trọng số, chỉ loại bỏ khi hoàn toàn không mang giá trị thông tin.

Kết quả: từ **20.099 phản hồi thô**, sau làm sạch giữ lại **≈ 15.092 đơn vị thông tin hiệu dụng (effective n)** – tương đương tỷ lệ giữ 75,1%. Chỉ 196 bản ghi bị loại bỏ hoàn toàn.

Trong quá trình phản biện, chúng tôi đã phát hiện và sửa **một lỗi kỹ thuật trong chính mô hình** (xem Mục 5), đồng thời truy ra một pass làm sạch trước đó đã **xóa nhầm ~4.964 phản hồi hợp lệ** (xem Mục 6). Cả hai phát hiện đều ảnh hưởng trực tiếp đến tính chính xác của phân tích, đã được khắc phục.

Bảng chỉ số làm sạch tổng quan

Nhóm	Mẫu thô	n phân tích	n hiệu dụng	Tỷ lệ giữ
1A – Giao hàng	12.955	12.780	9.377	72,4%
1B – Tài xế	801	799	630	78,7%
2A – Nhân viên Kho	4.892	4.861	3.827	78,2%
2B – Quản lý Tuyển	425	425	358	84,2%
3A – Văn phòng	917	917	798	87,0%
3B – Quản lý Cấp cao	109	109	102	93,3%
TỔNG	20.099	19.891	15.092	75,1%

Lưu ý: **n hiệu dụng** là tổng trọng số tin cậy, không phải số dòng – đây là con số phải dùng làm trọng số cho mọi chỉ số topline, eNPS, MEI và Phân tích Yếu tố Trọng yếu (Key Driver Analysis).

2. Nguyên tắc nền: vì sao giảm trọng số thay vì xóa

Phương pháp truyền thống dùng độ lệch chuẩn (standard deviation) làm tiêu chí: ai có độ lệch quá thấp (trả lời thẳng hàng) thì bị loại. Cách này có hai điểm mù nghiêm trọng:

- **Bắt nhầm:** trên thang đo toàn câu thuận chiều, một người hài lòng thật buộc phải chấm điểm giống nhau ở mọi câu. Họ bị phạt oan như thể trả lời ầu.
- **Bỏ sót:** người trả lời loạn/mâu thuẫn lại có độ lệch chuẩn CAO, nên lọt qua lưới hoàn toàn.

Giải pháp: thay một ngưỡng cứng bằng **tổ hợp đa chỉ số** cho ra một trọng số liên tục. Mỗi phản hồi vẫn được giữ lại trong dữ liệu nhưng đóng góp vào kết quả theo đúng mức độ đáng tin của nó. Triết lý: thà giữ một phản hồi yếu với trọng số 0,2 còn hơn xóa nó và làm im lặng một con người thật – đặc biệt với nhóm lao động trực tiếp, nơi việc xóa thường rơi đúng vào nhóm rủi ro nghỉ việc cao nhất.

3. Quy trình làm sạch: 5 bước

Bước 1 – Khử trùng lặp (Deduplication)

Áp dụng khác nhau theo nền dữ liệu, vì hai nhóm dùng hệ thống nội bộ (có mã định danh) còn bốn nhóm dùng biểu mẫu ẩn danh (không mã):

Nhóm	Phương pháp	Kết quả
1A, 1B (nội bộ)	Khử trùng theo ID nhân viên	0 bản trùng – xác nhận dữ liệu sạch
2A, 2B, 3A, 3B (biểu mẫu)	Chữ ký nội dung (Likert + eNPS + câu mở giống hệt ≥ 25 ký tự)	Chỉ 2A có 12 bản trùng thật; các nhóm khác 0

Công “câu mở ≥ 25 ký tự” được siết chặt có chủ đích: nếu chỉ khớp điểm Likert thì hàng nghìn người chấm giống nhau sẽ bị giết oan. Hai người viết trùng nguyên văn một câu dài thì gần như chắc chắn là một người nộp hai lần.

Bước 2 – Ba chỉ số phát hiện trả lời kém chất lượng

Chỉ số	Vai trò
Longstring	Đo chuỗi đáp án giống nhau dài nhất. Bắt cả thẳng hàng toàn phần lẫn từng phần – điều mà độ lệch chuẩn bỏ sót.
Khoảng cách Mahalanobis	Đo độ lệch đa biến trên toàn bộ thang đo (co rút Ledoit-Wolf, ngưỡng chi-bình-phương $p < 0,001$). Bắt người trả lời mâu thuẫn/loạn – điểm mù của độ lệch chuẩn.
Mâu thuẫn eNPS ↔ Likert	Phát hiện khi điểm hài lòng và điểm sẵn lòng giới thiệu đánh nhau (ví dụ Likert $\geq 4,5$ nhưng eNPS ≤ 6) – dấu hiệu trả lời thiếu chú tâm.

Bước 3 – Giải cứu theo độ nhất quán (quan trọng nhất)

Trên thang đo **không có câu đảo chiều** (đã kiểm chứng – xem Mục 4), người chấm thẳng hàng toàn phần KHÔNG mặc nhiên là trả lời ầu. Với mỗi người như vậy, mô hình tìm bằng chứng họ là người thật:

- Có viết câu trả lời mở thật hay không?
- Điểm eNPS có cùng chiều với điểm Likert không (chấm toàn điểm 5 và eNPS 9–10 là nhất quán)?

Gán trọng số theo số bằng chứng: **2 bằng chứng** → **×0,8**; 1 → ×0,5; 0 → ×0,2 và đánh dấu loại bỏ. Riêng người trả lời **trung lập toàn bộ** (chọn mức 3 ở mọi câu) bị áp trần ×0,5 dù có bằng chứng, vì trung lập không mang thông tin định hướng.

Bước 4 – Phân tầng và tính n hiệu dụng

Tầng	Điều kiện	Cách dùng
DROP	Flatline toàn phần VÀ không một bằng chứng nào	Loại khỏi phân tích (toàn hệ thống chỉ 196 bản)
DOWNWEIGHT	Trọng số < 0,7	Giữ lại nhưng đóng góp giảm theo trọng số
KEEP	Trọng số ≥ 0,7	Giữ đầy đủ

Phản hồi câu mở được gán cờ **dùng được (fit-for-use)** riêng: kể cả khi điểm Likert kém tin cậy, nếu có viết ý kiến thật thì vẫn dùng cho phân tích chủ đề. Con số chốt là **n hiệu dụng = tổng trọng số**, trả lời câu hỏi đúng: “còn bao nhiêu lượng thông tin tin cậy?” thay vì “còn bao nhiêu dòng?”.

Bước 5 – Kiểm định độ vững (Sensitivity)

Mọi chỉ số topline được tính hai lần – có và không trọng số. Nếu kết quả đảo chiều thì trọng số đang bẻ cong kết luận. Thực tế: chênh lệch tối đa chỉ +0,096 điểm và **không nhóm nào đổi thứ hạng** → trọng số chỉ tinh chỉnh độ tin cậy, không tạo câu chuyện giả.

4. Phản biện kỹ thuật: 5 kiểm định đã thực hiện

Vì dữ liệu sai thì mọi phân tích đều sai, chúng tôi đã chủ động tấn công chính mô hình của mình bằng năm kiểm định thực tế (không phải lý luận suông):

#	Kiểm định	Phát hiện	Kết luận
1	Parse điểm Likert đúng?	Giá trị thô và giá trị đọc khớp hoàn toàn	Đạt
2	Có câu đảo chiều không?	Cả 6 nhóm: 0 câu (tương quan dương 0,50–0,90)	Đạt
3	All-5 là hài lòng thật hay gặt bừa?	eNPS nhóm này = 9,69 (nếu nhiều phải ≈ 5,5)	Đạt
4	Mahalanobis gán cờ đúng người?	Phát hiện LỖI: gán cờ nhầm người trả lời tốt	Đã sửa
5	Hàng số trọng số có nhạy không?	Topline ổn định 3,90–3,92 dù đổi trọng số	Đạt

Kiểm định 3 là then chốt: nếu người chấm toàn điểm 5 là gặt bừa, điểm eNPS của họ phải gần ngẫu nhiên. Thực tế eNPS = 9,69 và đây là câu thang 0–10 có định dạng khác hẳn, buộc phải đọc và chấm riêng – bằng chứng độc lập rằng họ hài lòng thật.

5. Lỗi đã phát hiện và sửa: Mahalanobis phạt oan người trả lời tốt

Đây là lỗi nghiêm trọng nhất. Khi 55% mẫu nhóm 1A là flatline giống hệt nhau, “đám đông” trong không gian đa biến bị kéo dồn về một điểm. Hệ quả: thuật toán coi **bất kỳ ai trả lời có suy nghĩ, có biến thiên hợp lý** là “lệch đám” và gán cờ ngoại lệ – một kiểu phạt oan mới.

	Trước khi sửa	Sau khi sửa
Cách fit hiệp phương sai	Trên toàn mẫu (gồm cả flatline)	Chỉ trên người trả lời đa dạng
Số bản bị gắn cờ (1A)	1.756	683
Mẫu bị gắn cờ	3,4,4,4,4,4,3,3... (bình thường)	1,1,1,1,2,3,1,1,2... (loạn thật)

Cách sửa: fit ma trận hiệp phương sai chỉ trên những người đã thật sự biến thiên câu trả lời, để cấu trúc “bình thường” phản ánh biến thiên có nghĩa thay vì khối flatline. Sau sửa, n hiệu dụng toàn hệ thống tăng từ 14.395 lên 15.092 – phục hồi gần 700 người trả lời tử tế bị phạt oan.

6. Truy vết: pass làm sạch trước đã xóa quá tay ~4.964 phản hồi

Khi đối chiếu file nhận được với dữ liệu thô, chúng tôi phát hiện một pass làm sạch trước đó đã xóa cứng các phản hồi flatline – bao gồm cả những người **có viết ý kiến đóng góp**. Đây đúng là nhóm “người thật, có đầu tư” mà mô hình yêu cầu GIỮ với trọng số thấp, thay vì loại bỏ.

Nhóm	Raw thật	Bản đã cắt	Bị cắt oan
1A	12.955	10.359	2.596
2A	4.892	3.014	1.878
3A	917	667	250
1B	801	676	125
2B	425	321	104
3B	109	98	11
TỔNG	20.099	15.135	4.964

Kiểm định 5 định lượng tác hại: nếu xóa cứng toàn bộ flatline, điểm engagement nhóm 1A rơi từ 3,90 xuống 3,78 (giả tạo thấp đi 0,12 điểm). Vì vậy mọi con số cuối cùng đều được tính lại từ dữ liệu thô 20.099, **không dùng bản đã bị cắt**.

7. Giới hạn còn lại (minh bạch)

Hai điểm sau là giới hạn của dữ liệu, không phải lỗi quy trình, nhưng cần lưu ý khi đọc kết quả:

- Khử trùng nhóm biểu mẫu không thể tuyệt đối.** Không có mã định danh, một người cố tình nộp hai lần với câu trả lời hơi khác nhau sẽ lọt lưới. Rủi ro thấp (biểu mẫu nội bộ, không động cơ spam) nhưng tồn tại.
- eNPS làm “trọng tài” nhưng cũng là tự báo cáo.** Logic giả định người gặt bừa mọi câu Likert sẽ không tình cờ chấm eNPS nhất quán. Kiểm định cho thấy giả định đúng ở mức tổng thể, nhưng cấp cá nhân vẫn có thể sai vài trường hợp.

Khuyến nghị cho EES 2027: bật mã phản hồi (response-ID) và dấu thời gian tại nền tảng khảo sát – vẫn ẩn danh với người phân tích nhưng cho phép khử trùng chính xác tại nguồn. Đây là cách chuẩn các công ty nghiên cứu thị trường (ví dụ NielsenIQ) xử lý: tách định danh kỹ thuật khỏi định danh cá nhân.

8. Hướng dẫn sử dụng dữ liệu đã làm sạch

Mỗi tệp kết quả (đuôi _Scored_FROM_RAW) đã có sẵn các cột để phân tích đúng cách:

- **effective_weight** – dùng làm trọng số cho mọi chỉ số topline, eNPS, MEI, Key Driver Analysis.
- **text_usable = 1** – lọc các phản hồi dùng được cho phân tích câu hỏi mở.
- **tier_v2 = DROP** – 196 bản loại khỏi phân tích định lượng.
- **reliab_weight, longstring, maha_flag, contradiction, corroboration** – các cột chẩn đoán để rà soát từng trường hợp khi cần.

Memo này ghi lại quy trình tính đến thời điểm lập. Mọi thay đổi về dữ liệu nguồn hoặc tham số mô hình cần cập nhật lại bằng số liệu tương ứng.